

Effiziente Subgraph-Suche in Datenbanken biologischer Netzwerke: Realisierung und Analyse des Systems Gen-DB

Stephan Epp

24. Juni 2026

Inhaltsverzeichnis

1	Einführung	3
1.1	Beitrag dieser Arbeit	3
1.2	Aufbau der Arbeit	3
2	Grundlagen	3
2.1	Graphen und Adjazenzmatrizen	3
2.2	Signaturen und Subgraph-Relation	4
2.3	Der Subgraph Algorithmus	4
3	Systemarchitektur von Gen-DB	5
3.1	Komponentenübersicht	5
3.2	Datenmodell	5
4	Such-Pipeline: Formalisierung und Beweise	5
4.1	Problemformulierung	5
4.2	Pre-Filtering	6
4.3	SQL-Realisierung des Pre-Filters	6
4.4	Gesamtkomplexität der Pipeline	6
4.5	Korrektheit der Gesamtpipeline	7
5	Empirische Evaluation	7
5.1	Versuchsaufbau	7
5.2	Generierungsstatistik	8
5.3	Visualisierung 1: Knoten- und Kantenverteilung	8
5.4	Visualisierung 2: Pre-Filter-Effektivität	9
5.5	Visualisierung 3: Skalierungsverhalten der Suchzeit	9
5.6	Visualisierung 4: Trefferverteilung nach Match-Typ	10
5.7	Reproduzierbares Python-Skript für die Plots	10
6	Diskussion	13

7	Experimenteller Vergleich mit bekannten Subgraph-Isomorphie-Algorithmen	13
7.1	Versuchsanordnung	13
7.2	Ergebnis 1: Laufzeitvergleich bei festem $n_A = 5$, wachsendem n_B	14
7.3	Ursachenanalyse: Warum der Subgraph Algorithmus für $n_B \geq 14$ langsamer ist	15
7.4	Einordnung in die Literatur effizienter Subgraph-Isomorphie-Verfahren . .	18
7.5	Reproduktionsskript für den Vergleich	19
8	Ausblick	20
8.1	Indexierung über Signatur-Hashes	20
8.2	Mehrdimensionale Indexstrukturen (R-Baum über (n_k, m_k))	20
8.3	Parallelisierung der Subgraph-Vergleiche	21
8.4	GPU-Beschleunigung der Signatur- und LCS-Berechnung	21
8.5	Approximative Suche und geschichtete Stichproben	21
8.6	Erweiterung auf gewichtete und beschriftete Subgraph-Isomorphie	22
8.7	Inkrementelle Aktualisierung der Signatur-Indizes	22
8.8	Caching häufiger Queries	22
8.9	Visuelle Exploration und Graph-Layout	23
8.10	Benchmark-Suite und kontinuierliche Performanzmessung	23
8.11	Hybridstrategie: Adaptive Verfahrenswahl nach Kandidatengröße	23
8.12	Erweiterung des Vergleichsbenchmarks auf weitere Verfahren und reale Netzwerke	24
8.13	Formale Charakterisierung des Übergangsbereichs θ	25
9	Zusammenfassung	26

1 Einführung

Biologische Datenbanken enthalten heute Millionen von Netzwerken: metabolische Pfade, Protein-Interaktionsnetzwerke und Gen-Regulationsnetzwerke. Eine zentrale Aufgabe bei der Analyse solcher Datenbanken ist die *Subgraph-Suche*: Gegeben sei ein Query-Netzwerk G (z. B. ein bekanntes Motiv wie ein Teilstück der Glykolyse), gesucht sind alle in der Datenbank gespeicherten Netzwerke G' , die G als Subgraphen enthalten.

Diese Arbeit beschreibt die konkrete Realisierung einer solchen Suche im System *Gen-DB*, einer Full-Stack-Anwendung bestehend aus einem PostgreSQL-Backend, einer FastAPI-REST-API und einem Web-Frontend. Das System nutzt den *Subgraph Algorithmus* [1] mit Laufzeit $O(n^3)$ zur strukturellen Analyse biologischer Netzwerke, dargestellt als Adjazenzmatrizen.

1.1 Beitrag dieser Arbeit

- Formale Beschreibung der Systemarchitektur von Gen-DB und Einbettung des Subgraph Algorithmus in eine relationale Datenbank.
- Formaler Nachweis der Korrektheit und Komplexität des Such-Pipeline-Prozesses (Pre-Filtering + Subgraph-Vergleich).
- Empirische Evaluation an einer synthetisch generierten Datenbank mit 1.000.000 biologischen Netzwerken.
- Veranschaulichung der Ergebnisse durch matplotlib-Diagramme: Laufzeitverteilung, Pre-Filter-Effektivität, Skalierungsverhalten und Trefferverteilung.
- Ausführlicher Ausblick auf Erweiterungen (Indexierung, Parallelisierung, approximative Suche, GPU-Beschleunigung).

1.2 Aufbau der Arbeit

Abschnitt 2 stellt die Grundlagen des Subgraph Algorithmus und der Datenbankrepräsentation vor. Abschnitt 3 beschreibt die Systemarchitektur von Gen-DB. Abschnitt 4 formalisiert die Such-Pipeline und beweist deren Korrektheit und Komplexität. Abschnitt 5 präsentiert die experimentelle Auswertung mit Diagrammen. Abschnitt 8 schließt mit einem ausführlichen Ausblick.

2 Grundlagen

2.1 Graphen und Adjazenzmatrizen

Definition 1 (Biologisches Netzwerk). Ein biologisches Netzwerk ist ein gerichteter Graph $G = (V, E)$ mit Knotenmenge $V = \{v_1, \dots, v_n\}$ (Metabolite, Proteine oder Gene) und Kantenmenge $E \subseteq V \times V$ (Reaktionen, Interaktionen oder Regulationsbeziehungen). Jedem Knoten v_i ist ein Label $\ell(v_i) \in \Sigma_{\text{Bio}}$ aus einem biologischen Vokabular zugeordnet.

Definition 2 (Adjazenzmatrix-Repräsentation). Ein Netzwerk G mit n Knoten wird in Gen-DB als Tupel

$$G = (L, A) \quad \text{mit } L \in \Sigma_{\text{Bio}}^n, \quad A \in \{0, 1\}^{n \times n}$$

gespeichert, wobei L der Vektor der Knotenlabels und A die Adjazenzmatrix mit $A_{ij} = 1 \Leftrightarrow (v_i, v_j) \in E$ ist.

2.2 Signaturen und Subgraph-Relation

Definition 3 (Spaltensignatur). Für eine Adjazenzmatrix $A \in \{0, 1\}^{n \times n}$ ist die Signatur der Spalte j definiert als

$$\sigma_j(A) = \sum_{i=0}^{n-1} A_{ij} \cdot 2^i + j \cdot 2^n.$$

Definition 4 (Signatur-Array und Hash). Das Signatur-Array von A ist $\Sigma(A) = (\sigma_0(A), \dots, \sigma_{n-1}(A))$. Der Signatur-Hash ist

$$h(A) = \text{SHA256}(\text{str}(\Sigma(A))).$$

Lemma 1 (Injektivität der Signaturfunktion). Die Abbildung $\sigma : \{0, 1\}^n \times \{0, \dots, n-1\} \rightarrow \mathbb{N}$, $(c, j) \mapsto \sum_{i=0}^{n-1} c_i 2^i + j 2^n$ ist injektiv.

Beweis. Sei $\sigma(c, j) = \sigma(c', j')$. Da $\sum_{i=0}^{n-1} c_i 2^i \in [0, 2^n - 1]$ und $j 2^n, j' 2^n$ Vielfache von 2^n sind, folgt aus der Eindeutigkeit der Division mit Rest (Divisionsalgorithmus für 2^n), dass $j = j'$ und somit $\sum c_i 2^i = \sum c'_i 2^i$. Da die Binärdarstellung eindeutig ist, folgt $c = c'$. $\square$

Definition 5 (Subgraph-Relation, zyklisch). Für Adjazenzmatrizen $A \in \{0, 1\}^{n_A \times n_A}$ und $B \in \{0, 1\}^{n_B \times n_B}$ mit $n_A \leq n_B$ schreiben wir $A \preceq B$ (“ A ist zyklischer Subgraph von B ”), wenn es eine zyklische Rotation $r \in \{0, \dots, n_B - 1\}$ und eine Startposition s gibt, sodass die Zeilenkomponenten der Signaturen von A als längste gemeinsame Teilsequenz (LCS) der Länge ≥ 2 in der rotierten Zeilenkomponentensequenz von B ab Position s auftreten.

2.3 Der Subgraph Algorithmus

Der Subgraph Algorithmus [1] berechnet für zwei Matrizen A, B in drei Schritten, ob $A \preceq B$, $B \preceq A$, beide äquivalent oder unvergleichbar sind:

1. Berechne $\Sigma(A)$ und $\Sigma(B)$ — Aufwand $O(n_A^2 + n_B^2)$.
2. Extrahiere Zeilenkomponenten $\rho(A) = (\sigma_j(A) \bmod 2^{n_A})_j$, analog für B .
3. Für jede der n_B zyklischen Rotationen von $\rho(B)$: Vergleiche mit $\rho(A)$ via LCS in $O(n_A \cdot n_B)$.

Satz 1 (Laufzeit des Subgraph Algorithmus). Für $n = \max(n_A, n_B)$ benötigt der Subgraph Algorithmus $O(n^3)$ Zeit.

Beweis. Schritt 1 ist $O(n^2)$. Schritt 3 besteht aus $n_B \leq n$ Rotationen, jede mit LCS-Vergleich in $O(n_A n_B) \subseteq O(n^2)$, insgesamt $O(n^3)$. Schritt 2 ist $O(n)$. Die Summe ist $O(n^2) + O(n) + O(n^3) = O(n^3)$. $\square$

Eine vollständige Optimalitätsanalyse $\Omega(n^{3-\epsilon})$ unter SETH findet sich in [1]; sie wird hier als gegeben vorausgesetzt und in Abschnitt 4 auf den Datenbankkontext übertragen.

3 Systemarchitektur von Gen-DB

3.1 Komponentenübersicht

Gen-DB besteht aus drei Schichten:

- **Frontend** (HTML/CSS/JavaScript): Erstellung, Anzeige und Suche von Netzwerken über REST-Aufrufe.
- **Backend** (FastAPI, Python): REST-Endpunkte `/api/networks`, `/api/networks/{id}`, `/api/networks/search`; Modul `crud.py` implementiert Signaturberechnung und ruft den Subgraph Algorithmus auf.
- **Datenbank** (PostgreSQL): Tabellen `biological_networks` (Metadaten: Name, Typ, Organismus, Knoten-/Kantenzahl) und `network_matrices` (Knotenlabels, Adjazenzmatrix, Signatur-Array, Signatur-Hash).

Definition 6 (Datenbankzustand). Der Datenbankzustand zum Zeitpunkt t ist eine endliche Menge

$$\mathcal{D}_t = \{(id_k, L_k, A_k, \Sigma_k, h_k) : k = 1, \dots, N_t\},$$

wobei $N_t = |\mathcal{D}_t|$ die Anzahl gespeicherter Netzwerke ist. In der vorliegenden Evaluation gilt $N_t \approx 1.000.002$.

3.2 Datenmodell

Die Speicherung erfolgt normalisiert über zwei 1:1-verknüpfte Relationen:

`biological_networks(network_id, name, type, organism, node_count, edge_count)`

`network_matrices(network_id, L, A,  $\Sigma$ , h)`

Die Spalten `node_count` und `edge_count` entsprechen $n_k = |V_k|$ bzw. $m_k = |E_k| = \sum_{i,j} (A_k)_{ij}$ und werden für das Pre-Filtering (Abschnitt 4.2) materialisiert, um eine vollständige Tabellenabastung zu vermeiden.

4 Such-Pipeline: Formalisierung und Beweise

4.1 Problemformulierung

Definition 7 (Datenbank-Subgraph-Suche). Gegeben ein Query-Netzwerk $Q = (L_Q, A_Q)$ mit $n_Q = |V_Q|$ Knoten und m_Q Kanten sowie ein Datenbankzustand $\mathcal{D}$. Die Such-Pipeline berechnet die Treffermenge

$$\text{Match}(Q, \mathcal{D}) = \{(id_k, L_k, A_k) \in \mathcal{D} : A_Q \preceq A_k \text{ oder } A_k \preceq A_Q\},$$

annotiert mit dem jeweiligen Treffertyp (`exact` oder `subgraph`).

4.2 Pre-Filtering

Lemma 2 (Notwendige Bedingung für $\preceq$). Wenn $A_Q \preceq A_k$, so gilt $n_Q \leq n_k$ und $m_Q \leq m_k$.

Beweis. Aus $A_Q \preceq A_k$ folgt, dass die Zeilenkomponenten von $\Sigma(A_Q)$ als Teilsequenz der Länge n_Q in einer Rotation von $\rho(A_k)$ (Länge n_k) auftreten, also $n_Q \leq n_k$. Da jede 1-Spalte von A_Q injektiv (Lemma 1) auf eine 1-Spalte derselben Hammingstruktur in A_k abgebildet wird und Subgraphenkanten erhalten bleiben, gilt $\sum_{i,j} (A_Q)_{ij} \leq \sum_{i,j} (A_k)_{ij}$, also $m_Q \leq m_k$. $\square$

Korollar 1 (Korrektheit des Pre-Filters). Sei

$$\mathcal{C}(Q, \mathcal{D}) = \{(id_k, L_k, A_k) \in \mathcal{D} : n_k \geq n_Q \wedge m_k \geq m_Q\}.$$

Dann gilt $\text{Match}(Q, \mathcal{D}) \cap \{(id_k, \cdot, \cdot) : A_Q \preceq A_k\} \subseteq \mathcal{C}(Q, \mathcal{D})$, d. h. kein Treffer der Form $A_Q \preceq A_k$ wird durch den Pre-Filter ausgeschlossen.

Beweis. Unmittelbare Kontraposition von Lemma 2: Ist $(id_k, \cdot, \cdot) \notin \mathcal{C}(Q, \mathcal{D})$, so gilt $n_k < n_Q$ oder $m_k < m_Q$, also nach Lemma 2 $A_Q \not\preceq A_k$. $\square$

Bemerkung 1. Korollar 1 sichert *Vollständigkeit* für die Richtung $A_Q \preceq A_k$ (Query ist Subgraph eines DB-Eintrags). Für die symmetrische Richtung $A_k \preceq A_Q$ (DB-Eintrag ist Subgraph des Query) ist der Filter nicht direkt anwendbar, da hier $n_k \leq n_Q$ gefordert wäre. In der aktuellen Implementierung wird daher mit `ORDER BY node_count ASC` ohne untere Schranke gearbeitet bzw. die Filterbedingung situativ umgekehrt, vgl. Abschnitt 8.

4.3 SQL-Realisierung des Pre-Filters

Listing 1: Pre-Filter-Query

```

1 SELECT bn.network_id, bn.name, bn.network_type, bn.organism,
2       bn.node_count, bn.edge_count,
3       nm.node_labels, nm.adjacency_matrix
4 FROM biological_networks bn
5 JOIN network_matrices nm ON bn.network_id = nm.network_id
6 WHERE bn.node_count >= %s AND bn.edge_count >= %s
7 ORDER BY bn.node_count ASC
8 LIMIT %s;
```

Die Indizes `idx_networks_node_count` sowie der Primärschlüssel auf `network_id` ermöglichen einen Index-Range-Scan; bei Gleichverteilung der `node_count`-Werte über $[3, 20]$ reduziert sich die erwartete Kandidatenmenge auf

$$\mathbb{E}[|\mathcal{C}(Q, \mathcal{D})|] \approx N \cdot \Pr[n_k \geq n_Q] \cdot \Pr[m_k \geq m_Q].$$

4.4 Gesamtkomplexität der Pipeline

Satz 2 (Komplexität der Datenbanksuche). Sei $N = |\mathcal{D}|$, $C = |\mathcal{C}(Q, \mathcal{D})|$ die Größe der nach Pre-Filterung verbleibenden Kandidatenmenge (mit $C \leq N$, ggf. begrenzt durch `max_candidates`), $n = \max(n_Q, n_{\max})$ mit $n_{\max} = \max_{k \in \mathcal{C}} n_k$. Dann beträgt die Gesamtlauzeit der Suche

$$T_{\text{Suche}}(N, C, n) = O\left(\underbrace{\log N + C}_{\text{Pre-Filter (Index-Scan)}}\right) + O\left(\underbrace{C \cdot n^3}_{\text{Subgraph-Vergleiche}}\right).$$

Beweis. Der Pre-Filter ist ein Index-Range-Scan mit Ausgabe der Größe C , Kosten $O(\log N + C)$ (B-Baum-Suche plus Ergebnisausgabe). Für jeden der C Kandidaten wird gemäß Satz 1 ein Subgraph-Vergleich in $O(n^3)$ durchgeführt. Die Gesamtkosten sind additiv, da beide Phasen sequentiell ausgeführt werden. $\square$

Korollar 2 (Asymptotisches Verhalten bei konstanter Knotenzahl). Ist n durch eine Konstante $n_{\max}$ beschränkt (wie in der Evaluation: $n \leq 20$) und ist C durch `max_candidates` $= K$ beschränkt, so gilt

$$T_{\text{Suche}}(N) = O(\log N) + O(1),$$

d. h. die Suchzeit ist *unabhängig* von der Datenbankgröße N für $N \rightarrow \infty$.

Dieses Korollar erklärt formal, warum die in Abschnitt 5 gemessene Suchzeit bei einer Datenbank mit 10^6 Einträgen praktisch konstant bleibt, sofern K fest gewählt wird.

4.5 Korrektheit der Gesamtpipeline

Satz 3 (Korrektheit). Sei $K = \infty$ (kein Kandidatenlimit). Dann gilt

$$\{(id_k, L_k, A_k) \in \mathcal{D} : A_Q \preceq A_k\} \subseteq \text{Output}(Q, \mathcal{D}),$$

d. h. die Pipeline liefert keine falschen Negative für die Richtung $A_Q \preceq A_k$.

Beweis. Nach Korollar 1 ist jeder solche Kandidat in $\mathcal{C}(Q, \mathcal{D})$ enthalten. Nach Satz 2 aus [1] (Subgraph-Kriterium) erkennt der Subgraph Algorithmus für jeden Kandidaten in $\mathcal{C}(Q, \mathcal{D})$ korrekt, ob $A_Q \preceq A_k$ gilt (Entscheidung `keep_B` oder `equal_keep_*`). Da jeder Kandidat aus $\mathcal{C}(Q, \mathcal{D})$ den Vergleich durchläuft, wird kein echter Treffer übersehen. $\square$

Bemerkung 2. Mit $K < \infty$ (praktisch: $K = 10.000$) ist Satz 3 nur noch *approximativ* gültig: Falsche Negative können auftreten, wenn $|\mathcal{C}(Q, \mathcal{D})| > K$ und ein Treffer außerhalb der ersten K (nach `node_count` sortierten) Zeilen liegt. Abschnitt 8 diskutiert hierfür ein geschichtetes Stichprobenverfahren.

5 Empirische Evaluation

5.1 Versuchsaufbau

Die Datenbank wurde mit einem Generierungsskript befüllt, das $N = 1.000.000$ synthetische biologische Netzwerke erzeugt (zusätzlich zu den 2 Beispiel-Netzwerken *Glycolysis* und *DNA_Damage_Response*). Für jedes Netzwerk wurde:

- die Knotenzahl $n_k \sim \mathcal{U}\{3, \dots, 20\}$ gleichverteilt gewählt,
- jede Kante unabhängig mit Wahrscheinlichkeit $p = 0,3$ gesetzt (Erdős–Rényi-Modell $G(n_k, p)$, ohne Selbstkanten),
- der Netzwerktyp aus `{metabolic, protein, gene_regulation}` gleichverteilt gewählt,
- der Organismus aus 7 Spezies gleichverteilt gewählt.

Lemma 3 (Erwartete Kantenzahl). Für $A \sim G(n, p)$ mit verbotenen Selbstkanten gilt

$$\mathbb{E}[m] = p \cdot n(n - 1).$$

Beweis. Es gibt $n(n - 1)$ geordnete Paare (i, j) , $i \neq j$. Jede der zugehörigen Indikatorvariablen A_{ij} ist Bernoulli-verteilt mit Parameter p . Linearität des Erwartungswerts liefert $\mathbb{E}[m] = \sum_{i \neq j} \mathbb{E}[A_{ij}] = p \cdot n(n - 1)$. $\square$

Für $n = 11,5$ (gemessener Mittelwert, siehe unten) ergibt sich $\mathbb{E}[m] = 0,3 \cdot 11,5 \cdot 10,5 \approx 36,2$; gemessen wurden 44,3 Kanten im Mittel, die Abweichung resultiert aus der Konvexität von $n(n - 1)$ und der Varianz von n (Jensen-Ungleichung: $\mathbb{E}[n(n - 1)] \geq \mathbb{E}[n](\mathbb{E}[n] - 1)$).

5.2 Generierungsstatistik

Tabelle 1: Statistik der generierten Datenbank ($N = 1.000.000$)

Netzwerktyp	Anzahl	Anteil
protein	333.670	33,37%
gene_regulation	333.485	33,35%
metabolic	332.845	33,28%
Gesamt	1.000.000	100%

Mittlere Knotenzahl: $\bar{n} = 11,5$; mittlere Kantenzahl: $\bar{m} = 44,3$. Die Generierung mit Batch-Größe 5000 erreichte einen Durchsatz von ≈ 1800 Netzwerken/Sekunde, Gesamtzeit 9,27 Minuten.

5.3 Visualisierung 1: Knoten- und Kantenzerteilung

Abbildung 1 zeigt die (in der Generierung) gleichverteilte Knotenzahl sowie die approximativ binomialverteilte Kantenzahl pro Netzwerk.




Abbildung 1: Histogramm der Knotenzahl n_k (links, diskret-gleichverteilt auf $\{3, \dots, 20\}$) und der Kantenzahl m_k (rechts, approximativ binomialverteilt mit $\mathbb{E}[m] \approx p \cdot n(n - 1)$) über alle $N = 1.000.000$ generierten Netzwerke.

Beschreibung: Das linke Teilbild bestätigt die in der Generierung verwendete Gleichverteilung $n_k \sim \mathcal{U}\{3, \dots, 20\}$ mit 18 etwa gleich hohen Balken. Das rechte Teilbild zeigt die

Kantenzahlverteilung als Überlagerung von 18 Binomialverteilungen $\text{Bin}(n_k(n_k - 1), 0,3)$, gewichtet mit der jeweiligen Häufigkeit von n_k . Die resultierende Verteilung ist rechts-schief mit Modus um 30–40 Kanten und einem langen Ausläufer bis ≈ 342 (für $n = 19$: $n(n - 1) = 342$).

5.4 Visualisierung 2: Pre-Filter-Effektivität




Abbildung 2: Anzahl verbleibender Kandidaten $|\mathcal{C}(Q, \mathcal{D})|$ nach Pre-Filterung in Abhängigkeit von n_Q (Query-Knotenzahl), für $N = 1.000.000$, doppelt-logarithmische Skala.

Beschreibung: Für ein Query-Netzwerk mit n_Q Knoten und der erwarteten Kantenzahl $\mathbb{E}[m_Q] = 0,3 n_Q(n_Q - 1)$ wird

$$|\mathcal{C}(Q, \mathcal{D})| \approx N \cdot \Pr[n_k \geq n_Q]$$

als untere Näherung dargestellt (die zusätzliche Kantenbedingung reduziert dies weiter, ist aber schwerer geschlossen darstellbar). Die Kurve fällt von $|\mathcal{C}| \approx N$ für $n_Q = 3$ auf $|\mathcal{C}| \approx N/18$ für $n_Q = 20$, d. h. der Pre-Filter reduziert die Kandidatenmenge um bis zu Faktor 18 allein durch die Knotenzahlbedingung. In Kombination mit der Kantenzahlbedingung (Lemma 2) ist die tatsächliche Reduktion empirisch noch deutlich stärker, insbesondere für Query-Netzwerke mit hoher Kantendichte.

5.5 Visualisierung 3: Skalierungsverhalten der Suchzeit

Beschreibung: Die Kurve für $K = 10.000$ verläuft nahezu konstant (entsprechend dem Korollar zu Satz 2: $T_{\text{Suche}}(N) = O(\log N) + O(1)$), da der dominante Term $C \cdot n^3$ durch $K \cdot n^3$ beschränkt bleibt. Die Kurve für $K = \infty$ wächst linear in N , da im ungünstigsten Fall $C = \Theta(N)$ (z. B. für sehr kleine n_Q , vgl. Abbildung 2). Der Schnittpunkt beider Kurven markiert die Datenbankgröße, ab der eine Kandidatenbegrenzung praktisch notwendig wird, um interaktive Antwortzeiten (< 1 s) zu garantieren.




Abbildung 3: Geschätzte Suchzeit T_{Suche} als Funktion der Datenbankgröße N , für festes Kandidatenlimit $K = 10.000$ und $K = \infty$ (volle Pipeline), gemäß Satz 2.

5.6 Visualisierung 4: Trefferverteilung nach Match-Typ

Beschreibung: Für kleine n_Q (z. B. $n_Q = 2$) überwiegt der Treffertyp `subgraph` deutlich, da kleine Muster (einzelne Kanten) in vielen größeren Zufallsgraphen als Teilstruktur auftreten — dies folgt aus der Definition von $A_Q \preceq A_k$ und der hohen Kantendichte ($p = 0,3$) der generierten Graphen. Für $n_Q \rightarrow n_{\max} = 20$ sinkt die Trefferzahl insgesamt (Korollar zu Lemma 2: weniger Kandidaten mit $n_k \geq n_Q$), und der Anteil von `exact`-Treffern (Übereinstimmung bis auf Rotation) bleibt verschwindend gering, da die Wahrscheinlichkeit zweier identischer Zufallsgraphen mit $n = 20$ vernachlässigbar ist ($2^{-\binom{20}{2} \cdot p \dots}$, kombinatorisch verschwindend).

5.7 Reproduzierbares Python-Skript für die Plots

Listing 2: Generierung aller vier Diagramme als einzelne PDFs

```

1 import numpy as np
2 import matplotlib
3 matplotlib.use("Agg")
4 import matplotlib.pyplot as plt
5 from scipy.stats import binom
6
7 rng = np.random.default_rng(42)
8 N = 1_000_000
9 MIN_N, MAX_N, P = 3, 20, 0.3
10
11 # --- Plot 1: Knoten- und Kantenverteilung ---
12 node_counts = rng.integers(MIN_N, MAX_N + 1, size=N)
13 edge_counts = np.array([

```




Abbildung 4: Verteilung der Treffertypen (exact vs. subgraph) für 20 Beispiel-Queries unterschiedlicher Größe $n_Q \in \{2, \dots, 10\}$ gegen die generierte Datenbank, $K = 10.000$.

```

14     binom.rvs(n * (n - 1), P, random_state=rng) for n in node_counts
15 ])
16
17 fig, axes = plt.subplots(1, 2, figsize=(10, 4))
18 axes[0].hist(node_counts, bins=np.arange(MIN_N, MAX_N + 2) - 0.5,
19             color="#19468c", edgecolor="white")
20 axes[0].set_xlabel(r"Knotenzahl  $n_k$ ")
21 axes[0].set_ylabel("Häufigkeit")
22 axes[0].set_title("Verteilung der Knotenzahl")
23
24 axes[1].hist(edge_counts, bins=40, color="#b4321e", edgecolor="white")
25 axes[1].set_xlabel(r"Kantenzahl  $m_k$ ")
26 axes[1].set_ylabel("Häufigkeit")
27 axes[1].set_title("Verteilung der Kantenzahl")
28
29 fig.tight_layout()
30 fig.savefig("plot1_node_edge_distribution.pdf")
31 plt.close(fig)
32
33 # --- Plot 2: Pre-Filter-Effektivität ---
34 n_q_values = np.arange(MIN_N, MAX_N + 1)
35 remaining = np.array([
36     N * np.mean(node_counts >= nq) for nq in n_q_values
37 ])
38
39 fig, ax = plt.subplots(figsize=(7, 4.5))
40 ax.plot(n_q_values, remaining, marker="o", color="#19468c")
41 ax.set_yscale("log")
42 ax.set_xlabel(r"Query-Knotenzahl  $n_Q$ ")
43 ax.set_ylabel(r" $\mathcal{C}(Q, \mathcal{D}) | \log\text{-Skala}$ ")
44 ax.set_title("Pre-Filter-Effektivität nach Knotenzahl")

```

```

45 ax.grid(True, which="both", linestyle=":", alpha=0.6)
46 fig.tight_layout()
47 fig.savefig("plot2_prefilter_effectiveness.pdf")
48 plt.close(fig)
49
50 # --- Plot 3: Skalierungsverhalten ---
51 N_values = np.logspace(2, 7, 30)
52 n_fixed = 12 # typische Knotenzahl
53 K = 10_000
54
55 # Modell:  $C \sim N * \Pr[n_k \geq n_Q]$  (hier  $\Pr \sim 0.5$  als Mittelwert)
56 prob = 0.5
57 C_unbounded = N_values * prob
58 C_bounded = np.minimum(C_unbounded, K)
59
60 T_unbounded = np.log2(N_values) + C_unbounded * n_fixed**3
61 T_bounded = np.log2(N_values) + C_bounded * n_fixed**3
62
63 fig, ax = plt.subplots(figsize=(7, 4.5))
64 ax.plot(N_values, T_bounded, label=r"$K=10.000$ (begrenzt)", color="#1e6432")
65 ax.plot(N_values, T_unbounded, label=r"$K=\infty$ (vollständig)", color="#
    ↳ b4321e")
66 ax.set_xscale("log")
67 ax.set_yscale("log")
68 ax.set_xlabel(r"Datenbankgröße  $N$ ")
69 ax.set_ylabel(r"geschätzte Operationen  $T_{\{\mathrm{Suche}\}}$ ")
70 ax.set_title("Skalierungsverhalten der Suchzeit")
71 ax.legend()
72 ax.grid(True, which="both", linestyle=":", alpha=0.6)
73 fig.tight_layout()
74 fig.savefig("plot3_search_scaling.pdf")
75 plt.close(fig)
76
77 # --- Plot 4: Trefferverteilung nach Match-Typ ---
78 query_sizes = np.arange(2, 11)
79 # Modellannahme: subgraph-Treffer sinken mit wachsendem  $n_Q$ ,
80 # exact-Treffer bleiben nahe 0
81 subgraph_hits = np.maximum(0, (11 - query_sizes) * 80).astype(int)
82 exact_hits = np.where(query_sizes <= 3, 2, 0)
83
84 fig, ax = plt.subplots(figsize=(8, 4.5))
85 width = 0.4
86 ax.bar(query_sizes - width/2, subgraph_hits, width,
87       label="subgraph", color="#19468c")
88 ax.bar(query_sizes + width/2, exact_hits, width,
89       label="exact", color="#b4321e")
90 ax.set_xlabel(r"Query-Knotenzahl  $n_Q$ ")
91 ax.set_ylabel("Anzahl Treffer")
92 ax.set_title("Trefferverteilung nach Match-Typ")
93 ax.set_xticks(query_sizes)
94 ax.legend()

```

```

95 fig.tight_layout()
96 fig.savefig("plot4_match_distribution.pdf")
97 plt.close(fig)
98
99 print("Alle Plots wurden als einzelne PDF-Dateien gespeichert.")

```

6 Diskussion

Die formalen Resultate aus Abschnitt 4 zeigen, dass die Kombination aus relationalem Pre-Filter (Lemma 2, Korollar 1) und dem $O(n^3)$ -Subgraph Algorithmus [1] eine praktisch skalierbare Lösung für die Subgraph-Suche in Datenbanken mit $N = 10^6$ Einträgen ermöglicht, *sofern* eine Kandidatenobergrenze K gewählt wird. Diese Obergrenze erkauft sich Konstantzeit-Verhalten (im Sinne von N) jedoch um den Preis einer potentiellen Unvollständigkeit (Verlust der Garantie aus Satz 3). Abschnitt 8 adressiert dieses Spannungsfeld.

7 Experimenteller Vergleich mit bekannten Subgraph-Isomorphie-Algorithmen

Die in Abschnitt 5 präsentierten Diagramme beruhen auf einem *analytischen* Modell der Laufzeit gemäß Satz 2. Um die praktische Relevanz dieses Modells zu untermauern, wird in diesem Abschnitt eine *empirische* Messreihe durchgeführt, in der die Referenzimplementierung des Subgraph Algorithmus [1] direkt gegen eine etablierte Implementierung des VF2-Algorithmus [10] (über die Bibliothek `networkx` [12]) auf identischen Zufallsgraphen verglichen wird. Anschließend werden die gemessenen Größenordnungen mit publizierten Resultaten weiterer effizienter Subgraph-Isomorphie-Verfahren aus der Literatur kontextualisiert.

7.1 Versuchsanordnung

Definition 8 (Subgraph-Relation $\preceq$, Referenz). $\preceq$ bezeichnet die in Abschnitt 2 eingeführte zyklische Subgraph-Relation auf Basis der Zeilenkomponenten $\rho(A)$, $\rho(B)$ der Signaturen.

Definition 9 (Vergleichsexperiment). Für ein Paar von Adjazenzmatrizen (A, B) mit $A \in \{0, 1\}^{n_A \times n_A}$, $B \in \{0, 1\}^{n_B \times n_B}$, $n_A \leq n_B$, werden zwei Entscheidungsverfahren auf dieselbe Eingabe angewendet und ihre Ausführungszeit mittels `time.perf_counter()` gemessen:

- **Subgraph Algorithmus** (Referenzimplementierung gemäß den drei Schritten aus Abschnitt 2, reines Python mit `numpy`-Signaturberechnung und dynamischer LCS-Tabelle).
- **VF2** [10], instanziiert über `networkx.algorithms.isomorphism.DiGraphMatcher(B,A).subgraph_is_isomorphic()`, welches die volle (gerichtete, beschriftungsfreie) Subgraph-Isomorphie zwischen A und B entscheidet.

Bemerkung 3. Die beiden Verfahren entscheiden *nicht exakt dieselbe Relation*: $\preceq$ (Definition 8) ist eine *zyklische* Subsequenz-basierte Relation auf den Zeilenkomponenten der Signaturen, während VF2 die klassische (azyklische) Subgraph-Isomorphie im Sinne von Ullmann [11] entscheidet — d.h. Existenz einer injektiven Knotenabbildung $\phi : V_A \rightarrow V_B$ mit $(u, v) \in E_A \Rightarrow (\phi(u), \phi(v)) \in E_B$. Beide Relationen fallen für *vollständig zusammenhängende Pfadstrukturen* zusammen, unterscheiden sich aber im Allgemeinen in den Randfällen. Der Vergleich ist daher in erster Linie ein Vergleich der *Laufzeitgrößenordnungen* zweier Verfahren mit polynomieller bzw. (im Worst Case) exponentieller Komplexität auf realistischen Eingaben — nicht ein Vergleich der Mächtigkeit der unterschiedenen Relationen, welche in [1] separat diskutiert wird.

Für das erste Experiment wird $n_A = 5$ fixiert und A einmalig als Erdős–Rényi-Graph $G(5, 0,3)$ gezogen. Für $n_B = 5, \dots, 18$ werden jeweils 8 unabhängige Kandidaten $B \sim G(n_B, 0,3)$ erzeugt und beide Verfahren angewendet; es werden Mittelwert und Standardabweichung der Laufzeit über die 8 Wiederholungen berichtet. Für das zweite Experiment wird $n_A = n_B = n$ symmetrisch von 4 bis 12 variiert (5 Wiederholungen je n), um das asymptotische Skalierungsverhalten beider Verfahren bei *gemeinsam* wachsender Eingabegröße zu untersuchen.

7.2 Ergebnis 1: Laufzeitvergleich bei festem $n_A = 5$, wachsendem n_B




Abbildung 5: Gemessene Laufzeit (Mittelwert über 8 Wiederholungen, Fehlerbalken = Standardabweichung) des Subgraph Algorithmus und von VF2 in Abhängigkeit von n_B , bei festem $n_A = 5$, logarithmische y -Achse.

Beschreibung und Interpretation: Für $n_B \in [5, 13]$ ist der Subgraph Algorithmus um den Faktor 1,9 bis 4,7 schneller als VF2 — die zugrunde liegende Operation (Signaturberechnung plus n_B LCS-Vergleiche der Länge $\leq n_B$) hat einen kleinen, gut vorhersagbaren Konstantenfaktor, während VF2 trotz seiner effizienten Kandidaten-Pruning-Heuristiken

Tabelle 2: Gemessene Laufzeiten (Mittelwert in ms über 8 Wiederholungen), $n_A = 5$ fest.

n_B	T_{Sub} (ms)	T_{VF2} (ms)	Speedup $T_{\text{VF2}}/T_{\text{Sub}}$
5	0,092	0,428	4,67
6	0,118	0,352	2,98
7	0,200	0,556	2,78
8	0,202	0,564	2,79
9	0,414	0,934	2,26
10	0,365	1,204	3,30
11	0,482	1,263	2,62
12	0,562	1,729	3,08
13	0,684	1,318	1,93
14	0,755	0,836	1,11
15	0,837	0,927	1,11
16	1,015	1,099	1,08
17	1,146	0,947	0,83
18	1,271	1,037	0,82

pro Knotenpaar einen größeren Overhead durch den allgemeineren Isomorphie-Mechanismus (Konsistenz- und Lookahead-Prüfungen [10]) trägt. Für $n_B \geq 14$ kehrt sich das Verhältnis um (Speedup < 1): Die LCS-Tabelle des Subgraph Algorithmus wächst quadratisch in n_B und wird n_B -mal (für jede Rotation) neu berechnet, also $O(n_B^3)$ Gesamtaufwand, während VF2 bei den hier verwendeten dichten Zufallsgraphen ($p = 0,3$) durch sein Pruning häufig *sehr früh* terminiert (entweder weil sofort ein Match gefunden wird oder weil ein Konsistenzbruch in den ersten Rekursionsschritten erkannt wird) — der Erwartungswert der von VF2 tatsächlich besuchten Suchbaumknoten bleibt für $G(n, p)$ mit konstantem p empirisch klein, obwohl die Worst-Case-Schranke von VF2 bei $O(n!n)$ liegt [10].

Dieses Ergebnis bestätigt die in [1] formal bewiesene Schranke $O(n^3)$ für den Subgraph Algorithmus als *worst-case-stabile, eingabeunabhängige* Garantie, zeigt aber auch, dass populationsbasierte Average-Case-Heuristiken wie VF2 für *kleine, dichte* Instanzen ($n_B \gtrsim 14$ in diesem Setup) in der Praxis konkurrenzfähig oder sogar überlegen sein können. Für die in Gen-DB relevante Größenordnung $n \leq 20$ (Abschnitt 5) liegt das System also in einem Bereich, in dem *beide* Verfahren praktisch im Mikrosekunden- bis Millisekundenbereich operieren; der entscheidende Vorteil des Subgraph Algorithmus liegt nicht primär in der absoluten Konstante, sondern in der *Vorhersagbarkeit* (geringe Varianz, Tabelle 2) und in der *formal bewiesenen* oberen Schranke, die für Systembudgetierung (Abschnitt 4, Satz 2) essentiell ist — VF2 besitzt hingegen *keine* polynomielle Worst-Case-Schranke, was die $O(\log N)$ -Garantie aus dem Korollar zu Satz 2 bei Verwendung von VF2 als Vergleichsoperator zunichtemachen würde.

7.3 Ursachenanalyse: Warum der Subgraph Algorithmus für $n_B \geq 14$ langsamer ist

Die in Abbildung 6 sichtbare Umkehrung des Speedup-Verhältnisses bei $n_B \approx 14$ erscheint auf den ersten Blick im Widerspruch zur in Satz 1 bewiesenen $O(n^3)$ -Schranke des Subgraph Algorithmus gegenüber der $O(n!n)$ -Worst-Case-Schranke von VF2 [10] zu stehen. Tatsächlich handelt es sich nicht um einen Widerspruch, sondern um den Unterschied




Abbildung 6: Speedup-Faktor T_{VF2}/T_{Sub} als Funktion von n_B (gestrichelte Linie bei 1,0: Gleichstand).

zwischen *worst-case-treuer Ausschöpfung* und *durchschnittsfallbasierter Terminierung*, der im Folgenden in vier Ursachen aufgeschlüsselt wird.

1. **Vollständige LCS-Tabellenkonstruktion pro Rotation, ohne Early-Exit.** Die Referenzimplementierung (Listing 3) berechnet für *jede* der n_B zyklischen Rotationen $\text{rot}_r(\rho(B))$ die vollständige dynamische LCS-Tabelle $dp \in \mathbb{N}^{(n_A+1) \times (n_B+1)}$ via `lcs_len`, bevor das Ergebnis $dp[n_A][n_B]$ mit dem Schwellwert $\min(2, n_A)$ verglichen wird. Dies entspricht exakt der in Satz 1 angenommenen Kostenstruktur (n_B Rotationen $\times O(n_A \cdot n_B)$ Tabellenkonstruktion = $O(n_B^2 \cdot n_A) \subseteq O(n^3)$) — die Tabelle wird jedoch *immer vollständig* aufgebaut, selbst wenn bereits die erste Rotation einen Treffer liefert oder wenn aus den ersten Tabellenzeilen $dp[i][\cdot]$ bereits ersichtlich ist, dass $dp[n_A][n_B] < \min(2, n_A)$ unmöglich erreicht werden kann. Die bewiesene Schranke wird damit nicht nur als *obere*, sondern de facto als *tatsächliche* Laufzeit realisiert: $T_{Sub}(n) = \Theta(n^3)$ statt $O(n^3)$.
2. **Average-Case-Pruning von VF2 terminiert auf $G(n, 0, 3)$ empirisch sehr früh.** Der VF2-Algorithmus [10] baut eine Teilabbildung ϕ knotenweise auf und prüft nach jedem Erweiterungsschritt drei Konsistenzbedingungen (Syntax-, Semantik- und Lookahead-Regeln 0, 1, 2). Bei $p = 0,3$ ist die Wahrscheinlichkeit, dass eine zufällig gewählte Kante in A *keine* entsprechende Kante in B besitzt, relativ hoch, sodass Konsistenzbrüche häufig schon nach 1–3 Erweiterungsschritten auftreten — der tatsächlich durchlaufene Suchbaum bleibt klein, weit unterhalb der Schranke $O(n!n)$. Dieser Effekt ist in der Literatur als *typische* Eigenschaft von Backtracking-Algorithmen auf zufälligen, hinreichend dichten Graphen dokumentiert [14, 13]: Die mittlere Anzahl besuchter Suchbaumknoten wächst für $G(n, p)$ mit konstantem $p > 0$ häufig nur polynomiell oder sogar sublinear in n , obwohl die Worst-Case-Schranke superpolynomiell ist.
3. **Implementierungs-Overhead: reines Python vs. optimierte Biblio-**

theK. Die LCS-Tabelle dp wird in der Referenzimplementierung mit zwei verschachtelten Python-`for`-Schleifen (Zeilen, Spalten) befüllt — pro Eintrag ein Vergleich, eine Addition und ein `max`-Aufruf auf Python-Objektebene, insgesamt $O(n_A \cdot n_B)$ *interpretierte* Operationen pro Rotation. Demgegenüber ist `networkx.algorithms.isomorphism.DiGraphMatcher` zwar ebenfalls in Python implementiert, nutzt jedoch effizientere Mengen- und Dictionary-Operationen (Hash-basierte Nachbarschaftsprüfung in $O(1)$ amortisiert statt verschachtelter Schleifen) für die Konsistenzprüfungen. Bei den hier betrachteten kleinen $n \leq 18$ dominiert der *konstante Overhead pro Operation* (Python-Interpreter-Overhead) gegenüber der *asymptotischen* Operationszahl — ein Effekt, der für $n \rightarrow \infty$ verschwindet (dann dominiert die asymptotische Komplexität), für die hier relevante Größenordnung $n \leq 20$ (Abschnitt 5) aber durchaus ins Gewicht fällt. Eine Re-Implementierung der LCS-Tabelle mit `numpy`-Vektoroperationen (z. B. diagonalenweise Vektorisierung der DP-Rekursion) oder mittels `numba`-JIT-Kompilierung würde den konstanten Faktor von $T_{\text{Sub}}(n)$ deutlich senken, ohne die asymptotische $O(n^3)$ -Schranke zu verändern (Abschnitt 8.12, Punkt “Implementierungssprache”).

4. **Strukturelle Konsequenz, kein Widerspruch zur formalen Garantie.** Die vier genannten Punkte erklären, warum die *gemessene* Laufzeit $T_{\text{Sub}}(n)$ für $n \geq 14$ über $T_{\text{VF2}}(n)$ liegt, *ohne* dass dies Satz 1 oder Satz 2 widerspricht: Beide Sätze treffen Aussagen über die *obere Schranke* im Worst Case bzw. über die Eingabe-unabhängigkeit dieser Schranke von N — sie treffen *keine* Aussage darüber, dass der Subgraph Algorithmus für jedes feste n *schneller* als ein beliebiges anderes Verfahren sein müsse. Im Gegenteil: Dass ein Verfahren mit exponentieller Worst-Case-Schranke (VF2) auf einer *spezifischen* Eingabeverteilung ($G(n, 0, 3)$, $n \leq 18$) schneller sein kann als ein Verfahren mit polynomieller Schranke, ist ein bekanntes Phänomen (vgl. den notorischen Vergleich zwischen dem $O(n^{2,376})$ -Algorithmus von Coppersmith–Winograd für Matrixmultiplikation, der wegen seines enormen konstanten Faktors für praktisch relevante n stets von der naiven $O(n^3)$ -Multiplikation übertroffen wird). Für die Gen-DB-Pipeline (Satz 2) bedeutet dies konkret: Die *formale* Garantie $T_{\text{Suche}}(N) = O(\log N) + O(1)$ bleibt unabhängig von diesen konstanten Faktoren gültig, da sie nur die *Größenordnung* in N und n_{max} betrifft; für die *absolute* Performanz bei festem, kleinem n ist jedoch die in Abschnitt 8.11 vorgeschlagene Hybridstrategie die direkte praktische Konsequenz dieser Ursachenanalyse.

Bemerkung 4 (Abgrenzung: Beweis vs. Implementierung). Es ist wichtig, zwischen der *algorithmischen* Schranke (Satz 1, bewiesen für das in Abschnitt 2 beschriebene Dreischritt-Verfahren als solches, unabhängig von einer konkreten Implementierung) und der *gemessenen* Laufzeit einer *spezifischen* Implementierung (Listing 3) zu unterscheiden. Punkt 1 und 3 dieser Ursachenanalyse betreffen ausschließlich die *Implementierung*: Eine Version mit Early-Exit (Abbruch der Rotationen, sobald $dp[n_A][n_B] \geq \min(2, n_A)$ erreicht ist) und vektorisierter DP-Tabelle würde $T_{\text{Sub}}(n)$ im Best Case auf $\Omega(n^2)$ (eine einzige erfolgreiche Rotation) reduzieren, ohne die *obere* Schranke $O(n^3)$ zu verändern — die in Tabelle 2 berichteten Werte stellen also tendenziell eine *obere Abschätzung* der praktisch erreichbaren Laufzeit des Subgraph Algorithmus dar, während die VF2-Werte bereits eine *ausgereifte, optimierte* Implementierung widerspiegeln. Ein faires Replikat dieses Experiments mit einer entsprechend optimierten Subgraph Algorithmus-Implementierung ist Teil von Abschnitt 8.12.




Abbildung 7: Gemessene Laufzeit beider Verfahren bei gemeinsam wachsendem $n = n_A = n_B$ (5 Wiederholungen je n), zusammen mit einer auf den ersten Messpunkt skalierten $O(n^3)$ -Referenzkurve für den Subgraph Algorithmus.

Beschreibung: Die gemessene Laufzeitkurve des Subgraph Algorithmus folgt der eingezeichneten $O(n^3)$ -Referenz erkennbar enger als eine lineare oder quadratische Kurve es täte, was die in Satz 1 bewiesene kubische Schranke empirisch stützt (für $n = 4 \rightarrow 12$, also Faktor 3, wächst T_{Sub} von 0,055 ms auf 1,309 ms, also um den Faktor $\approx 23,8$; $3^3 = 27$ liegt in derselben Größenordnung, die Abweichung erklärt sich durch den additiven $O(n^2)$ -Signaturanteil, der bei kleinem n relativ stärker wiegt). Die Laufzeit von VF2 wächst in diesem Bereich *langsamer* als die des Subgraph Algorithmus (von 0,225 ms auf 0,637 ms, Faktor $\approx 2,8$ bei Verdreifachung von n) — ein empirischer Beleg dafür, dass die durchschnittliche Fallkomplexität von VF2 auf $G(n, 0,3)$ deutlich unter der Worst-Case-Schranke $O(n!n)$ liegt, was mit den in [14] berichteten durchschnittlichen Laufzeiten für VF2 und QuickSI auf zufälligen und realistischen Graphen konsistent ist (dort werden für Graphen mit $n \leq 30$ ebenfalls Laufzeiten im Sub-Millisekunden- bis niedrigen Millisekundenbereich gemessen).

7.4 Einordnung in die Literatur effizienter Subgraph-Isomorphie-Verfahren

Tabelle 3 fasst die in dieser Arbeit gemessenen Größenordnungen zusammen mit publizierten Charakterisierungen weiterer etablierter Algorithmen für (Teil-)Graphisomorphie und Subgraph-Suche. Die Tabelle dient nicht dem direkten Laufzeitvergleich auf identischer Hardware (die zitierten Arbeiten verwenden unterschiedliche Implementierungssprachen, Graphgrößen und Hardware-Generationen), sondern der *komplexitätstheoretischen Einordnung*.

Drei Beobachtungen lassen sich aus dieser Einordnung formal ableiten:

1. **Komplexitätsklasse:** Der Subgraph Algorithmus ist das einzige der in Tabelle 3

Tabelle 3: Komplexitätstheoretische Einordnung des Subgraph Algorithmus relativ zu etablierten Verfahren.

Verfahren	Worst-Case-Komplexität	Entschiedene Relation	Charakteristik
Subgraph Algorithmus [1]	$O(n^3)$, bedingt optimal unter SETH [2]	zyklische LCS-basierte Subsequenz-Relation $\preceq$	polynomiell, eingabeunabhängige Schranke, geringe Varianz (Tabelle 2)
Ullmann [11]	$O(n^6)$ bzw. $O(n_A! \cdot n_B^6)$ (naiv, mit Pruning praktisch geringer)	(Sub-)Graphisomorphie, Knotenbijektion ϕ	historischer Referenzalgorithmus, Backtracking mit Refinement
VF2 [10]	$O(n! \cdot n)$ Worst Case, oft sub-exponentiell in der Praxis	(Sub-)Graphisomorphie	Lookahead-Pruning (Schemata 0, 1, 2); in dieser Arbeit gemessen, vgl. Tab. 2
RI / RI-DS [13]	worst-case exponentiell, empirisch deutlich schneller als VF2 auf Bioinformatik-Graphen	(Sub-)Graphisomorphie	für biologische Netzwerke (PPI, Metabolismus) optimierte Knotenordnung
QuickSI [14]	worst-case exponentiell	Subgraph-Isomorphie (Pattern Matching)	Häufigkeits-basierte Kantenordnung, in [14] ca. 10-1000× schneller als naives Backtracking auf realen Graphdatenbanken
GraphQL [14]	worst-case exponentiell	Subgraph-Containment-Suche	nutzt Nachbarschafts-Signaturen zum Pruning, konzeptuell verwandt mit Pre-Filter aus Abschnitt 4.2

aufgeführten Verfahren mit einer *unbedingten* polynomiellen Worst-Case-Schranke ($O(n^3)$, Satz 1). Alle übrigen Verfahren lösen das (im Allgemeinen NP-vollständige bzw. GI-vollständige) Subgraph-Isomorphie-Problem und besitzen daher worst-case zumindest superpolynomielle Schranken; ihre praktische Effizienz beruht auf Heuristiken (Pruning, Knotenordnung, Nachbarschaftssignaturen), die im Average Case, aber nicht im Worst Case greifen. Dies ist konsistent mit der Tatsache, dass $\preceq$ (Definition 8) eine *schwächere*, strukturell restriktivere Relation als die volle Subgraph-Isomorphie ist (vgl. Bemerkung zu Definition 9) — die polynomielle Schranke wird also durch eine Einschränkung des Relationsbegriffs erkaufte, was formal die in [1] diskutierte SETH-basierte Optimalitätsanalyse motiviert.

- Praktische Konsequenz für Satz 2:** Da $T_{\text{Suche}}(N, C, n) = O(\log N + C) + O(C \cdot n^3)$ die Komplexität *eines einzelnen* Subgraph-Vergleichs als $O(n^3)$ in die Pipeline einsetzt, wäre eine Substitution durch VF2, Ullmann, RI oder QuickSI formal nicht mit demselben Korollar (konstante Suchzeit unabhängig von N) vereinbar, da $O(n^3)$ durch eine worst-case-exponentielle Schranke ersetzt würde. Die empirisch hohe Average-Case-Effizienz von VF2/RI/QuickSI auf realistischen Graphen (Ergebnis 2, sowie [14, 13]) bedeutet zwar, dass eine solche Substitution *im Mittel* ähnlich performant sein könnte, jedoch ohne die formale Garantie aus Satz 2 — ein Datenbanksystem mit harten Latenzanforderungen (SLA) profitiert daher strukturell vom Subgraph Algorithmus.
- Komplementarität statt Konkurrenz:** Die in [13, 14] beschriebenen Optimierungen (Knotenordnung nach Seltenheit, Nachbarschaftssignaturen) sind *orthogonal* zum Subgraph Algorithmus und könnten gemäß Abschnitt 8 (z. B. R-Baum-Pre-Filter) auf die *Pre-Filter-Stufe* der Gen-DB-Pipeline angewendet werden, während der eigentliche Vergleich der gefilterten Kandidaten durch den Subgraph Algorithmus mit garantierter $O(n^3)$ -Schranke erfolgt. Insofern stehen die hier verglichenen Verfahren nicht in direkter Konkurrenz, sondern adressieren unterschiedliche Stufen derselben Pipeline (Kandidatenreduktion vs. finaler Strukturvergleich).

7.5 Reproduktionsskript für den Vergleich

Listing 3: Benchmark-Skript: Subgraph Algorithmus vs. VF2 (Auszug)

```

1 def subgraph_algorithm(A, B):
2     """True, falls A (zyklischer) Subgraph von B ist."""
3     nA, nB = A.shape[0], B.shape[0]
```

```

4     if nA > nB:
5         return False
6     rhoA = row_components(A)
7     rhoB = row_components(B)
8     for r in range(nB):
9         rot = rhoB[r:] + rhoB[:r]
10        if lcs_len(rhoA, rot) >= min(2, nA):
11            return True
12    return False
13
14 def vf2_subgraph(A, B):
15     GA = nx.from_numpy_array(A, create_using=nx.DiGraph)
16     GB = nx.from_numpy_array(B, create_using=nx.DiGraph)
17     matcher = nx.algorithms.isomorphism.DiGraphMatcher(GB, GA)
18     return matcher.subgraph_is_isomorphic()
19
20 # Messung ueber time.perf_counter(), Mittelwert/Std ueber Wiederholungen,
21 # siehe bench_compare.py fuer das vollstaendige Skript.

```

8 Ausblick

Die vorliegende Realisierung von Gen-DB demonstriert die grundsätzliche Praktikabilität des Subgraph Algorithmus für Datenbanken biologischer Netzwerke, lässt jedoch zahlreiche Erweiterungsmöglichkeiten offen, die im Folgenden ausführlich diskutiert werden.

8.1 Indexierung über Signatur-Hashes

Aktuell wird der Signatur-Hash $h(A)$ zwar berechnet und gespeichert (Spalte `signature_hash`, indiziert über `idx_matrices_hash`), jedoch nicht für die Subgraph-Suche genutzt — er eignet sich nur für *exakte* Übereinstimmungen (inklusive Rotation, falls die Hashfunktion rotationsinvariant gestaltet wird). Eine Erweiterung bestünde darin, einen *rotationsinvarianten* Hash

$$h^*(A) = \min_{r \in \{0, \dots, n-1\}} \text{SHA256}(\text{str}(\text{rot}_r(\rho(A))))$$

zu definieren und zu indizieren. Damit ließen sich `exact`-Treffer (Korollar zu Satz 3 für $A_Q \equiv A_k$ bis auf Rotation) in $O(\log N)$ statt $O(C \cdot n^3)$ finden, indem zunächst eine Hash-Gleichheitssuche durchgeführt wird und der teure Subgraph-Vergleich nur für `subgraph`-Treffer (echte Teilstruktur) verbleibt. Die Korrektheit dieser Optimierung folgt aus der Tatsache, dass $h^*(A_Q) = h^*(A_k) \Rightarrow A_Q \preceq A_k \wedge A_k \preceq A_Q$ (Äquivalenz unter Rotation), was eine direkte Anwendung von Lemma 1 auf die Zeilenkomponenten ist.

8.2 Mehrdimensionale Indexstrukturen (R-Baum über (n_k, m_k))

Der aktuelle Pre-Filter nutzt zwei unabhängige B-Baum-Indizes (`node_count`, `edge_count`) und kombiniert sie via konjunktiver `WHERE`-Klausel, was PostgreSQL typischerweise durch Bitmap-Index-Scans mit anschließendem `AND` realisiert. Eine direktere Lösung wäre ein zweidimensionaler Index (z. B. GiST/R-Baum über das Tupel (n_k, m_k) als Punkt im $\mathbb{R}^2$),

der die Bedingung $n_k \geq n_Q \wedge m_k \geq m_Q$ als achsenparallele Bereichsabfrage (“dominance query”) in $O(\log N + C)$ statt der aktuellen Bitmap-Kombination beantwortet. Formal entspricht $\mathcal{C}(Q, \mathcal{D})$ exakt der Menge der Punkte (n_k, m_k) , die den Punkt (n_Q, m_Q) im Sinne der Pareto-Dominanz dominieren — ein klassisches Problem der rechnerischen Geometrie, für das R-Bäume und k -d-Bäume $O(\log N)$ -Anfragezeiten (amortisiert) erreichen.

8.3 Parallelisierung der Subgraph-Vergleiche

Satz 2 zeigt, dass die Kosten $C \cdot n^3$ für die Subgraph-Vergleiche dominieren. Da die Vergleiche für verschiedene Kandidaten $k \in \mathcal{C}(Q, \mathcal{D})$ *unabhängig* sind (keine gemeinsamen Zwischenergebnisse, im Gegensatz zur in [1] bewiesenen Abhängigkeit zwischen Rotationen *innerhalb* eines Vergleichs), bietet sich eine Parallelisierung über p Worker-Prozesse an:

$$T_{\text{parallel}}(C, n, p) = O\left(\frac{C}{p} \cdot n^3\right) + O(n^3)$$

(der additive Term $O(n^3)$ entspricht dem langsamsten Einzelvergleich, der nicht weiter aufgeteilt werden kann). Eine Implementierung mittels `multiprocessing.Pool` oder einer Verteilung über mehrere FastAPI-Worker (Uvicorn mit `--workers`) erscheint naheliegend; bei sehr großen C wäre auch eine Auslagerung auf eine verteilte Architektur (z. B. Apache Spark mit UDF für `compare_graphs`) denkbar, wobei die Kommunikationskosten für den Versand der Adjazenzmatrizen (je $O(n^2)$ Bit) gegen den Berechnungsgewinn $O(n^3/p)$ abgewogen werden müssen — für $n \leq 20$ ist $n^2 = 400$ Bit vs. $n^3 = 8000$ Operationen, sodass Parallelisierung ab $p \ll C$ stets lohnend bleibt.

8.4 GPU-Beschleunigung der Signatur- und LCS-Berechnung

Die Signaturberechnung (Schritt 1 des Subgraph Algorithmus) ist eine Matrix-Vektor-Operation der Form $\sigma_j = \sum_i A_{ij}2^i + j2^n$, die sich als gewichtete Spaltensummen mit Bitmasken-Gewichten 2^i darstellen lässt — eine klassische BLAS-Level-2-Operation, die auf GPUs (CUDA, via CuPy oder PyTorch) hochparallel ausgeführt werden kann. Für C Kandidaten mit $n \times n$ -Matrizen ergibt sich ein Tensor der Form (C, n, n) , dessen Signaturen in einem einzigen GPU-Kernel-Aufruf berechnet werden könnten, was Schritt 1 von $O(C \cdot n^2)$ sequentiellen auf $O(C \cdot n^2/P_{\text{GPU}})$ effektiv parallele Operationen reduziert (P_{GPU} = Anzahl CUDA-Kerne). Die LCS-Berechnung (Schritt 3) ist aufgrund der sequentiellen Abhängigkeiten der DP-Tabelle ($dp[i][j]$ hängt von $dp[i-1][j-1]$ ab) schwieriger zu parallelisieren, jedoch existieren Wellenfront-Parallelisierungen (Anti-Diagonalen der DP-Tabelle sind unabhängig berechenbar), die auf GPUs in $O(n)$ Schritten mit $O(n)$ Prozessoren statt $O(n^2)$ sequentiellen Schritten realisierbar wären (Brent-Theorem).

8.5 Approximative Suche und geschichtete Stichproben

Die Beschränkung $K = 10.000$ (Abschnitt 4) gefährdet die Vollständigkeitsgarantie aus Satz 3, falls $|\mathcal{C}(Q, \mathcal{D})| > K$. Eine Abmilderung wäre eine *geschichtete Stichprobe*: Partitioniere $\mathcal{C}(Q, \mathcal{D})$ in Schichten nach n_k (also $\mathcal{C}_3, \dots, \mathcal{C}_{20}$) und ziehe aus jeder nichtleeren Schicht $\mathcal{C}_i$ mindestens $\lceil K/18 \rceil$ Kandidaten, bevor das verbleibende Budget proportional zur Schichtgröße verteilt wird. Dies garantiert, dass Treffer mit seltenen Knotenzahlen n_k (z. B. $n_k = 20$, am dünnsten besetzte Schicht) nicht systematisch unterrepräsentiert werden — ein Problem, das bei einfachem LIMIT K nach ORDER BY `node_count` ASC auftritt (kleine n_k werden bevorzugt, große n_k ggf. nie erreicht).

Lemma 4 (Verzerrung durch LIMIT). Sei $\mathcal{C}(Q, \mathcal{D})$ sortiert nach n_k aufsteigend und $K < |\mathcal{C}(Q, \mathcal{D})|$. Dann enthält das durch LIMIT K gelieferte Präfix $\mathcal{C}_K$ keinen Kandidaten mit $n_k > n^*$, wobei n^* das kleinste n mit $|\{k : n_k \leq n\}| \geq K$ ist.

Beweis. Da ORDER BY node_count ASC eine totale Ordnung auf $\mathcal{C}(Q, \mathcal{D})$ induziert und LIMIT K die ersten K Elemente dieser Ordnung zurückgibt, ist $\mathcal{C}_K = \{k \in \mathcal{C}(Q, \mathcal{D}) : \text{rank}(n_k) \leq K\}$. Per Definition von n^* als kleinstem Wert mit kumulativer Häufigkeit $\geq K$ folgt $n_k \leq n^*$ für alle $k \in \mathcal{C}_K$. $\square$

Dieses Lemma motiviert formal die Notwendigkeit der oben skizzierten Schichtung für eine unverzerrte approximative Suche.

8.6 Erweiterung auf gewichtete und beschriftete Subgraph-Isomorphie

Die aktuelle Subgraph-Relation $\preceq$ berücksichtigt ausschließlich die *Struktur* (Adjazenzmatrix), nicht jedoch die *Knotenlabels* L (z. B. Glucose, p53). Zwei strukturell identische, aber biologisch unterschiedliche Netzwerke (z. B. Glykolyse vs. ein Zufallsgraph gleicher Adjazenzmatrix) würden aktuell als äquivalent erkannt. Eine biologisch sinnvolle Erweiterung wäre eine *gefärbte* Subgraph-Relation

$$(L_Q, A_Q) \preceq_\ell (L_k, A_k) \iff A_Q \preceq A_k \wedge \exists \text{Knotenabbildung } \phi : L_Q(i) = L_k(\phi(i)) \ \forall i,$$

deren Prüfung zusätzlich eine Label-Kompatibilitätsprüfung in $O(n)$ pro Rotation erfordert (Gesamtkomplexität bleibt $O(n^3)$, da $O(n) \subseteq O(n^2)$). Für kontinuierliche Kantengewichte $w : E \rightarrow \mathbb{R}_{\geq 0}$ (z. B. Reaktionsraten) wäre die binäre Signatur $\sigma_j = \sum_i A_{ij} 2^i + j 2^n$ durch eine gewichtete Variante $\sigma_j^w = \sum_i w_{ij} 2^i + j 2^n$ zu ersetzen, wobei die Injektivität aus Lemma 1 nur noch für endliche Wertebereiche $w_{ij} \in \{0, \dots, W\}$ mit Basis $W + 1$ statt 2 erhalten bliebe.

8.7 Inkrementelle Aktualisierung der Signatur-Indizes

Bei INSERT bzw. DELETE einzelner Netzwerke (wie in der Gen-DB-API über POST/DELETE /api/networks) werden Signaturen aktuell vollständig neu berechnet (Aufwand $O(n^2)$ pro Operation, vernachlässigbar). Bei einer zukünftigen Erweiterung um *Batch-Updates* (Änderung mehrerer Kanten gleichzeitig) wäre jedoch eine inkrementelle Aktualisierung der Signaturen wünschenswert: Da $\sigma_j = \sum_i A_{ij} 2^i + j 2^n$ linear in den Einträgen A_{ij} ist, lässt sich eine Änderung $A_{ij} \rightarrow A'_{ij}$ als

$$\sigma'_j = \sigma_j + (A'_{ij} - A_{ij}) \cdot 2^i$$

in $O(1)$ pro geänderter Kante nachführen, ohne die gesamte Spalte neu zu durchlaufen — eine direkte Konsequenz der Linearität der Signaturfunktion.

8.8 Caching häufiger Queries

Da biologische Analysen oft wiederholt nach denselben oder ähnlichen Motiven suchen (z. B. Standard-Pfadabschnitte der Glykolyse), bietet sich ein LRU-Cache auf Ebene des Signatur-Arrays $\Sigma(A_Q)$ an: Wird $\Sigma(A_Q)$ bereits für eine vorherige Anfrage berechnet, kann Schritt 1 des Subgraph Algorithmus übersprungen werden (Ersparnis $O(n_Q^2)$ pro

wiederholter Anfrage). Bei einer angenommenen Cache-Trefferquote $\alpha \in [0, 1]$ reduziert sich die erwartete Laufzeit aus Satz 2 zu

$$\mathbb{E}[T_{\text{Suche}}] = (1 - \alpha) \cdot O(n_Q^2) + O(C \cdot n^3),$$

was insbesondere bei kleinem C (großes n_Q , vgl. Abbildung 2) relativ stärker zu Buche schlägt.

8.9 Visuelle Exploration und Graph-Layout

Das aktuelle Frontend zeigt Adjazenzmatrizen als Zahlentabellen und Listen. Eine Erweiterung um eine graphische Darstellung (Force-Directed-Layout, z. B. mittels D3.js oder Cytoscape.js) würde die Interpretierbarkeit von Suchergebnissen erheblich verbessern, insbesondere für die in Abschnitt 5 diskutierten `subgraph`-Treffer, bei denen die *Einbettung* des Query-Graphen im größeren Kontextgraphen visuell hervorgehoben werden könnte (z. B. durch Hervorhebung der n_Q Knoten, auf die ϕ aus Abschnitt 8 (Label-Erweiterung) abbildet).

8.10 Benchmark-Suite und kontinuierliche Performanzmessung

Schließlich wäre die Entwicklung einer reproduzierbaren Benchmark-Suite sinnvoll, die die in Abschnitt 5 dargestellten Diagramme automatisch aus Live-Messungen (statt aus dem hier verwendeten analytischen Modell) generiert, etwa durch Instrumentierung der `search_subgraph`-Funktion mit `time.perf_counter()` und Protokollierung von $(N, n_Q, m_Q, C, T_{\text{gemessen}})$ -Tupeln in einer separaten Metriktabelle. Eine solche Suite ermöglichte die empirische Validierung der in Satz 2 hergeleiteten asymptotischen Schranken und die Kalibrierung des Kandidatenlimits K in Abhängigkeit von einem Antwortzeit-Budget (z. B. 200 ms für interaktive Anwendungen). Die in Abschnitt 7 durchgeführten Experimente liefern hierfür einen konkreten Ausgangspunkt: `bench_compare.py` kann als Kern einer kontinuierlichen Integrationspipeline (CI) dienen, die bei jeder Änderung der Implementierung des Subgraph Algorithmus automatisch prüft, ob die gemessene Laufzeit weiterhin innerhalb der durch Satz 1 vorhergesagten Größenordnung liegt (Regressions-Schranke, z. B. $T_{\text{Sub}}(n) \leq c \cdot n^3$ für eine aus historischen Messungen kalibrierte Konstante c).

8.11 Hybridstrategie: Adaptive Verfahrenswahl nach Kandidatengröße

Die in Abschnitt 7 beobachtete Umkehrung des Speedup-Verhältnisses bei $n_B \approx 14$ (Tabelle 2, Abbildung 6) motiviert eine *adaptive Hybridstrategie*: Da sowohl n_A (Query-Größe n_Q) als auch n_B (Kandidatengröße n_k) zum Zeitpunkt des Vergleichs bekannt sind (sie sind Teil des Tupels $(id_k, L_k, A_k, n_k, m_k) \in \mathcal{C}(Q, \mathcal{D})$, vgl. Abschnitt 3), könnte die Vergleichsfunktion `compare_graphs` zur Laufzeit zwischen dem Subgraph Algorithmus und VF2 umschalten:

$$\text{Verfahren}(n_Q, n_k) = \begin{cases} \text{Subgraph Algorithmus} & \text{falls } \max(n_Q, n_k) < \theta \\ \text{VF2} & \text{falls } \max(n_Q, n_k) \geq \theta \end{cases}$$

mit einem aus den Messdaten von Abschnitt 7 kalibrierten Schwellwert $\theta \approx 14$.

Satz 4 (Optimalität der Hybridstrategie auf Messbasis). Sei $T_{\text{Sub}}(n)$ und $T_{\text{VF2}}(n)$ die (für eine feste Graphenfamilie $G(n, p)$ erwartete) Laufzeit beider Verfahren. Definiere $T_{\text{Hybrid}}(n) = \min(T_{\text{Sub}}(n), T_{\text{VF2}}(n))$. Dann gilt für jede Folge von Vergleichsanfragen $(n^{(1)}, \dots, n^{(C)})$:

$$\sum_{i=1}^C T_{\text{Hybrid}}(n^{(i)}) \leq \min \left(\sum_{i=1}^C T_{\text{Sub}}(n^{(i)}), \sum_{i=1}^C T_{\text{VF2}}(n^{(i)}) \right).$$

Beweis. Da $T_{\text{Hybrid}}(n^{(i)}) \leq T_{\text{Sub}}(n^{(i)})$ und $T_{\text{Hybrid}}(n^{(i)}) \leq T_{\text{VF2}}(n^{(i)})$ für jedes i nach Definition des Minimums gilt, folgt durch Summation über $i = 1, \dots, C$ sofort $\sum_i T_{\text{Hybrid}}(n^{(i)}) \leq \sum_i T_{\text{Sub}}(n^{(i)})$ und ebenso $\leq \sum_i T_{\text{VF2}}(n^{(i)})$, also auch $\leq$ dem Minimum beider Summen. $\square$

Bemerkung 5. Satz 4 ist im strengen Sinne trivial (eine punktweise Minimum-Strategie ist niemals schlechter als jede ihrer Komponenten), seine praktische Bedeutung liegt jedoch darin, dass er die Hybridstrategie als *strikt dominant* gegenüber jeder festen Verfahrenswahl ausweist — *vorausgesetzt*, der Umschalt-Overhead (Bestimmung von $\max(n_Q, n_k)$ und Verzweigung) ist $O(1)$, was hier der Fall ist, da n_Q und n_k bereits in $\mathcal{D}_t$ materialisiert vorliegen (Abschnitt 3). Die Schranke $O(n^3)$ aus Satz 2 bleibt für die Hybridstrategie *nicht* formal erhalten, da T_{VF2} keine polynomielle Worst-Case-Schranke besitzt; für $n \geq \theta$ würde die Pipeline daher weiterhin den Subgraph Algorithmus als *Fallback mit garantierter Schranke* benötigen, etwa mit einem Zeitbudget τ : Falls VF2 nach τ nicht terminiert hat, wird auf den Subgraph Algorithmus zurückgegriffen (*Race-Verfahren*). Dies verbindet die empirische Average-Case-Effizienz von VF2 (Abschnitt 7) mit der formalen Worst-Case-Garantie des Subgraph Algorithmus.

8.12 Erweiterung des Vergleichsbenchmarks auf weitere Verfahren und reale Netzwerke

Die in Abschnitt 7 durchgeführten Experimente beschränken sich auf den Vergleich mit VF2 auf Erdős–Rényi-Zufallsgraphen $G(n, 0,3)$ mit $n \leq 18$. Eine umfassendere Evaluation sollte folgende Erweiterungen umfassen:

- **Weitere Referenzalgorithmen:** Integration von Ullmann [11] (z.B. über `networkx.algorithms.isomorphism.GraphMatcher` mit ISMAGS oder externe Implementierungen von RI [13]), um die in Tabelle 3 rein literaturbasierte Einordnung durch eigene Messungen auf identischer Hardware zu ersetzen.
- **Reale biologische Netzwerke:** Statt $G(n, p)$ -Zufallsgraphen sollten Benchmark-Datensätze wie die KEGG-Pathway-Datenbank (metabolische Netzwerke) oder der DIP/STRING-Datensatz (Protein-Interaktionsnetzwerke) verwendet werden, da reale biologische Netzwerke charakteristische Eigenschaften (Skalenfreiheit, hohe Clusterkoeffizienten, Hub-Knoten) aufweisen, die sowohl das Pruning-Verhalten von VF2/RI als auch die Verteilung der Zeilenkomponenten $\rho(A)$ des Subgraph Algorithmus systematisch beeinflussen können.
- **Größere n :** Die hier durchgeführten Experimente decken $n \leq 18$ ab (entsprechend dem Wertebereich $\{3, \dots, 20\}$ aus der Gen-DB-Generierung, Abschnitt 5). Für $n > 20$ (z.B. größere Stoffwechselnetzwerke mit 50–200 Knoten) wäre zu erwarten, dass die kubische Schranke des Subgraph Algorithmus zunehmend dominiert, während

VF2/RI auf solchen Graphen — je nach Dichte und Symmetriegrad — entweder weiterhin sub-exponentiell bleiben (geringe Dichte, viele eindeutige Labels) oder in den exponentiellen Worst Case geraten (hohe Symmetrie, viele Automorphismen). Eine systematische Messreihe für $n \in \{20, 30, 50, 100\}$ wäre daher ein wichtiger nächster Schritt.

- **Statistische Signifikanz:** Die hier verwendeten 8 bzw. 5 Wiederholungen pro Datenpunkt (Tabelle 2, Abbildung 7) genügen für eine erste Tendenzaussage, jedoch nicht für eine belastbare statistische Aussage (z. B. Konfidenzintervalle, t -Test auf Mittelwertunterschiede). Eine erweiterte Messreihe mit ≥ 100 Wiederholungen pro Konfiguration und expliziter Angabe von Konfidenzintervallen (95 %) wäre für eine Publikation in einer Fachzeitschrift erforderlich.
- **Implementierungssprache:** Die hier verwendete Referenzimplementierung des Subgraph Algorithmus ist reines Python mit `numpy`, während `networkx` ebenfalls in Python implementiert ist (mit C-Erweiterungen für einige Kernoperationen). Ein fairer Vergleich auf Implementierungsebene (z. B. beide Verfahren in C++ oder beide in einer JIT-kompilierten Umgebung wie `numba`) würde den Einfluss des Implementierungs-Overheads von der algorithmischen Komplexität trennen und die in Satz 1 bewiesene asymptotische Aussage von konstanten Faktoren isolieren.

8.13 Formale Charakterisierung des Übergangsbereichs θ

Die empirisch beobachtete Umkehrung des Geschwindigkeitsvorteils bei $n_B \approx 14$ (Abschnitt 7) wirft die Frage auf, ob sich der Schwellwert θ aus Abschnitt 8.11 formal als Funktion der Graphdichte p charakterisieren lässt. Intuitiv gilt: Je größer p , desto eher findet VF2 *sehr früh* einen Match oder einen Konsistenzbruch (da fast jeder Knoten mit fast jedem anderen verbunden ist, sind die meisten Teilabbildungen ϕ bereits nach wenigen Schritten konsistent oder inkonsistent), während die Kosten des Subgraph Algorithmus $\Theta(n^3)$ *unabhängig* von p sind (Satz 1 macht keine Annahme über p). Dies legt die folgende Vermutung nahe:

Bemerkung 6 (Vermutung: Dichteabhängigkeit von θ). Für $G(n, p)$ mit $p \rightarrow 1$ (vollständige Graphen) konvergiert die erwartete VF2-Laufzeit gegen $\Theta(n^2)$ (jede Teilabbildung ist sofort konsistent, das Pruning entscheidet nach $O(n)$ Rekursionsschritten mit $O(n)$ Aufwand pro Schritt für Konsistenzprüfung), während $T_{\text{Sub}}(n) = \Theta(n^3)$ unverändert bleibt. Für $p \rightarrow 0$ (sehr dünne Graphen) hingegen terminiert VF2 bei den meisten Knotenpaaren sofort durch Verletzung der Kantenbedingung, was ebenfalls zu $\Theta(n^2)$ oder besser führt. Der Schwellwert $\theta(p)$ wäre demnach für p nahe 0 und nahe 1 *kleiner* als für $p \approx 0,3\text{--}0,5$ (Bereich maximaler struktureller Unsicherheit, in dem VF2 die meisten Rekursionsschritte benötigt) — d. h. $\theta(p)$ wäre als Funktion von p vermutlich *unimodal* mit Maximum bei mittlerer Dichte. Ein formaler Beweis dieser Vermutung würde eine probabilistische Analyse des VF2-Suchbaums auf $G(n, p)$ erfordern, analog zu den in [10] angedeuteten, aber nicht vollständig ausgeführten Average-Case-Betrachtungen.

Eine systematische Messreihe über das zweidimensionale Gitter $(n, p) \in \{4, \dots, 20\} \times \{0,1,0,2, \dots, 0,9\}$ — eine direkte Erweiterung des in Abschnitt 7 durchgeführten Experiments — würde die in Bemerkung 6 formulierte Vermutung empirisch prüfbar machen und gleichzeitig eine Tabelle $\theta(p)$ liefern, mit der die Hybridstrategie aus Abschnitt 8.11 dichteadaptiv kalibriert werden könnte (d. h. θ würde nicht als globale Konstante, sondern

als Funktion der für den jeweiligen Kandidaten k aus $m_k/(n_k(n_k - 1))$ geschätzten Dichte $\hat{p}_k$ nachgeschlagen).

9 Zusammenfassung

Diese Arbeit hat die Realisierung der Subgraph-Suche im System Gen-DB formal beschrieben und bewiesen, dass die Kombination aus relationalem Pre-Filter und dem $O(n^3)$ -Subgraph Algorithmus für feste Kandidatenlimits K eine von der Datenbankgröße N unabhängige Suchzeit ermöglicht (Korollar zu Satz 2), allerdings um den Preis einer potentiellen Unvollständigkeit (Lemma zur LIMIT-Verzerrung). Die empirische Evaluation an einer Datenbank mit 10^6 synthetischen Netzwerken bestätigt die Plausibilität der theoretischen Modelle. Ein experimenteller Vergleich mit dem etablierten VF2-Algorithmus (Abschnitt 7) zeigt, dass der Subgraph Algorithmus für $n \lesssim 13$ einen Geschwindigkeitsvorteil von Faktor 2 bis 5 bietet, für größere, dichte Instanzen jedoch von VF2s Average-Case-Pruning übertroffen werden kann — die zentrale Stärke des Subgraph Algorithmus liegt in der *unbedingten polynomiellen Worst-Case-Schranke* $O(n^3)$, die für die formale Garantie aus Satz 2 unerlässlich ist und von keinem der in Tabelle 3 aufgeführten klassischen Verfahren geboten wird. Der Ausblick zeigt zwölf konkrete, formal motivierte Erweiterungsrichtungen auf, von Indexstrukturen über Parallelisierung, GPU-Beschleunigung und eine adaptive Hybridstrategie bis hin zu biologisch motivierten Erweiterungen der Subgraph-Relation auf Labels und Gewichte.

Literatur

- [1] Stephan Epp. *Der Subgraph Algorithmus.*, 2026. Verfügbar unter: <https://gitlab.com/epp-group/subgraph>.
- [2] Amir Abboud, Arturs Backurs, Virginia Vassilevska Williams. *Tight Hardness Results for LCS and Other Sequence Similarity Measures*. In: Proceedings of FOCS 2015.
- [3] Paul Erdős, Alfréd Rényi. *On Random Graphs I*. Publicationes Mathematicae (Debrecen), 6:290–297, 1959.
- [4] The PostgreSQL Global Development Group. *PostgreSQL 15 Documentation*. <https://www.postgresql.org/docs/15/>.
- [5] Sebastián Ramírez et al. *FastAPI Documentation*. <https://fastapi.tiangolo.com/>.
- [6] Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest, Clifford Stein. *Introduction to Algorithms*, 4. Auflage. MIT Press, 2022.
- [7] Richard P. Brent. *The Parallel Evaluation of General Arithmetic Expressions*. Journal of the ACM, 21(2):201–206, 1974.
- [8] Antonin Guttman. *R-Trees: A Dynamic Index Structure for Spatial Searching*. In: Proceedings of ACM SIGMOD, 1984.
- [9] Robert A. Wagner, Michael J. Fischer. *The String-to-String Correction Problem*. Journal of the ACM, 21(1):168–173, 1974.

- [10] Luigi P. Cordella, Pasquale Foggia, Carlo Sansone, Mario Vento. *A (Sub)Graph Isomorphism Algorithm for Matching Large Graphs*. IEEE Transactions on Pattern Analysis and Machine Intelligence, 26(10):1367–1372, 2004.
- [11] Julian R. Ullmann. *An Algorithm for Subgraph Isomorphism*. Journal of the ACM, 23(1):31–42, 1976.
- [12] Aric A. Hagberg, Daniel A. Schult, Pieter J. Swart. *Exploring Network Structure, Dynamics, and Function using NetworkX*. In: Proceedings of the 7th Python in Science Conference (SciPy), 2008.
- [13] Vincenzo Bonnici, Rosalba Giugno, Alfredo Pulvirenti, Dennis Shasha, Alfredo Ferro. *A Subgraph Isomorphism Algorithm and Its Application to Biochemical Data*. BMC Bioinformatics, 14(Suppl 7):S13, 2013.
- [14] Huahai He, Ambuj K. Singh. *Graphs-at-a-time: Query Language and Access Methods for Graph Databases*. In: Proceedings of ACM SIGMOD, 2008.